

Hybrid 通用任务重型 A/B 测试正式报告

执行摘要

本报告面向公开发布，使用新的 4x3 通用任务重型矩阵评估当前锁定版 hybrid 策略。

测试对象覆盖结构化通用任务，而不是 ACL-X 专项任务。

发布结论：GO。

测试基线

Run ID: 20260415_110636_t2_refresh

策略锁名称: aclx-strategy-freeze-2026-04-14-t0-t1-stable

生成时间: 2026-04-15 11:06:36

矩阵规模: 12 个任务，覆盖 t0/t1/t2/t3。

Baseline 失败任务数: 0。

总体结果

基线总 token: 167281

Hybrid 总 token: 114125

聚合 token 优化: 31.78%

基线总耗时: 686.96s

Hybrid 总耗时: 315.18s

聚合时间优化: 54.12%

基线平均质量: 99.25

Hybrid 平均质量: 100.00

质量差值: 0.75

分层汇总

层级	任务数	基线 Tokens	Hybrid Tokens	Token 优化	基线耗时	Hybrid 耗时	时间优化	基线质量	Hybrid 质量
t0	3	25563	23719	7.21%	52.55s	50.77s	3.38%	100.00	100.00

层级	任务数	基线 Tokens	Hybrid Tokens	Token 优化	基线耗时	Hybrid 耗时	时间优化	基线质量	Hybrid 质量
t1	3	49123	29085	40.79%	258.67s	85.90s	66.79%	100.00	100.00
t2	3	59416	30742	48.26%	225.69s	87.20s	61.36%	100.00	100.00
t3	3	33179	30579	7.84%	150.06s	91.31s	39.15%	97.00	100.00

任务矩阵

层级	组别	任务	基线 Tokens	Hybrid Tokens	Token 优化	基线耗时	Hybrid 耗时	时间优化	基线质量	Hybrid 质量
t0	1	Store pickup brief	8476	8246	2.71%	20.97s	17.46s	16.76%	100	100
t0	2	Meeting capacity brief	8543	8275	3.14%	15.90s	16.19s	-1.83%	100	100
t0	3	Field outage note brief	8544	7198	15.75%	15.68s	17.13s	-9.23%	100	100
t1	1	Blank shipment code review	16009	9756	39.06%	75.15s	29.95s	60.15%	100	100
t1	2	Zero attendee review	16124	9582	40.57%	98.15s	30.11s	69.33%	100	100
t1	3	Unknown locker review	16990	9747	42.63%	85.37s	25.84s	69.73%	100	100
t2	1	Delivery slot repair	22400	10388	53.62%	70.95s	29.55s	58.35%	100	100
t2	2	Maintenance window repair	22790	10341	54.62%	66.18s	32.32s	51.17%	100	100
t2	3	Shift label repair	14226	10013	29.61%	88.56s	25.33s	71.40%	100	100
t3	1	Warehouse cycle count playbook	10354	10228	1.22%	49.30s	27.95s	43.30%	100	100
t3	2	Vendor maintenance handoff guide	11560	10216	11.63%	51.14s	31.67s	38.07%	100	100
t3	3	Site readiness manual	11265	10135	10.03%	49.62s	31.69s	36.13%	91	100

解读与边界

结论仅适用于可结构化、可验证、可闭环的通用任务范围。

这不是对任意开放式任务或无限复杂任务的普遍保证。

聚合维度优于基线且平均质量不退化，才构成公开发布证据。

结论

在本次重型矩阵覆盖范围内，当前锁定版 hybrid 具备公开发布条件。