

Hybrid 通用任务重型 A/B 测试正式报告

执行摘要

本报告面向公开发布，使用新的 4x3 通用任务重型矩阵评估当前锁定版 hybrid 策略。

测试对象覆盖结构化通用任务，而不是 ACL-X 专项任务。

发布结论：GO。

测试基线

Run ID: 20260413_160451

策略锁名称: aclx-strategy-freeze-2026-04-13-t3-shell-trimmed

生成时间: 2026-04-13 16:44:52

矩阵规模: 12 个任务，覆盖 t0/t1/t2/t3。

Baseline 失败任务数: 0。

总体结果

基线总 token: 219253

Hybrid 总 token: 116487

聚合 token 优化: 46.87%

基线总耗时: 1780.31s

Hybrid 总耗时: 617.57s

聚合时间优化: 65.31%

基线平均质量: 99.25

Hybrid 平均质量: 100.00

质量差值: 0.75

分层汇总

层级	任务数	基线 Tokens	Hybrid Tokens	Token 优化	基线耗时	Hybrid 耗时	时间优化	基线质量	Hybrid 质量
t0	3	13407	15031	-12.11%	69.70s	49.05s	29.62%	100.00	100.00

层级	任务数	基线 Tokens	Hybrid Tokens	Token 优化	基线耗时	Hybrid 耗时	时间优化	基线质量	Hybrid 质量
t1	3	145412	45676	68.59%	1177.31s	321.49s	72.69%	100.00	100.00
t2	3	25600	24721	3.43%	244.64s	128.98s	47.28%	100.00	100.00
t3	3	34834	31059	10.84%	288.66s	118.05s	59.11%	97.00	100.00

任务矩阵

层级	组别	任务	基线 Tokens	Hybrid Tokens	Token 优化	基线耗时	Hybrid 耗时	时间优化	基线质量	Hybrid 质量
t0	1	Store pickup brief	6568	6094	7.22%	21.22s	15.39s	27.50%	100	100
t0	2	Meeting capacity brief	3552	6020	-69.48%	21.74s	20.56s	5.41%	100	100
t0	3	Field outage note brief	3287	2917	11.26%	26.74s	13.11s	50.98%	100	100
t1	1	Blank shipment code review	56541	11917	78.92%	328.53s	48.87s	85.12%	100	100
t1	2	Zero attendee review	52829	17625	66.64%	409.33s	110.34s	73.04%	100	100
t1	3	Unknown locker review	36042	16134	55.24%	439.45s	162.28s	63.07%	100	100
t2	1	Delivery slot repair	6492	8305	-27.93%	89.05s	45.08s	49.38%	100	100
t2	2	Maintenance window repair	6426	8376	-30.35%	74.52s	41.83s	43.87%	100	100
t2	3	Shift label repair	12682	8040	36.60%	81.08s	42.08s	48.10%	100	100
t3	1	Warehouse cycle count playbook	18114	14918	17.64%	110.35s	36.25s	67.15%	100	100
t3	2	Vendor maintenance handoff guide	11203	8077	27.90%	105.94s	34.75s	67.20%	100	100
t3	3	Site readiness manual	5517	8064	-46.17%	72.37s	47.05s	34.99%	91	100

解读与边界

结论仅适用于可结构化、可验证、可闭环的通用任务范围。
这不是对任意开放式任务或无限复杂任务的普遍保证。
聚合维度优于基线且平均质量不退化，才构成公开发布证据。

结论

在本次重型矩阵覆盖范围内，当前锁定版 hybrid 具备公开发布条件。